Utilizzo di una rete neurale ricorrente LSTM per il riconoscimento delle emozioni in video: un'analisi preliminare

Carmine Citro: c.citro23@studenti.unisa.it[a], Alessandro Cavaliere: a.cavaliere41@studenti.unisa.it[a]

[a] *Università degli Studi di Salerno, Dipartimento di Informatica, Salerno, Italy*

Abstract

Il progetto "Emotion Gait" esplora l'uso dell'intelligenza artificiale per il riconoscimento delle emozioni attraverso l'analisi dell'andatura umana. Questo approccio non intrusivo non richiede l'inquadramento del volto del soggetto, rendendolo applicabile in una varietà di contesti, tra cui la progettazione di case intelligenti, la gestione di emergenze, la videosorveglianza e l'ambito medico. Utilizzando il modello VAD per mappare le emozioni in uno spazio tridimensionale e un modello di posa 3D per analizzare l'andatura, il progetto sfrutta le reti neurali ricorrenti, in particolare LSTM e CNN, per elaborare dati sequenziali e prevedere tendenze future. Questo lavoro evidenzia l'importanza delle caratteristiche affettive, come angoli, distanze, aree e volumi, nell'apprendimento del modello, contribuendo a una comprensione più profonda dell'intersezione tra intelligenza artificiale e riconoscimento delle emozioni.

1. Descrizione del Problema

Nel contesto di un mondo sempre più interconnesso, la necessità di interpretare accuratamente le emozioni umane si è rivelata cruciale in una serie di settori, tra cui la progettazione di abitazioni intelligenti, la gestione di situazioni di emergenza, la videosorveglianza e l'assistenza sanitaria. Tuttavia, la maggior parte delle tecniche esistenti per il riconoscimento delle emozioni si basano su metodi che possono essere considerati invasivi, poiché richiedono la focalizzazione sul volto dell'individuo o la sua partecipazione attiva. Questo rappresenta un ostacolo significativo per l'implementazione di tali metodi in molte situazioni reali. In risposta a queste limitazioni, è stata sviluppata una tecnologia innovativa che utilizza l'intelligenza artificiale per identificare le emozioni attraverso l'analisi del movimento umano, o andatura. Questo metodo non invasivo non necessita di inquadrare il volto dell'individuo e può essere applicato anche con video di risoluzione inferiore. Inoltre, l'andatura umana può essere rilevata senza la necessità di una collaborazione attiva da parte del soggetto, rendendo questa tecnologia estremamente versatile e adatta a una vasta gamma di applicazioni. Nonostante i vantaggi offerti da questo approccio, la creazione di un sistema efficace per il riconoscimento delle emozioni attraverso l'andatura comporta una serie di sfide. Queste includono la gestione di sequenze di lunghezza variabile, il tracciamento di dipendenze a lungo termine, la conservazione dell'informazione relativa all'ordine e la condivisione di parametri all'interno della sequenza. Per superare queste sfide, i ricercatori stanno impiegando reti neurali ricorrenti, in particolare le reti Long Short-Term Memory (LSTM), per processare dati sequenziali e prevedere tendenze future. Nonostante i progressi significativi in questo campo, esiste ancora un ampio margine per migliorare l'accuratezza e l'efficacia del riconoscimento delle emozioni attraverso l'andatura. Questo studio esamina le ultime ricerche e sviluppi in questo ambito, con un focus particolare sulle tecniche di apprendimento profondo e sulle caratteristiche affettive utilizzate per potenziare l'apprendimento delle reti LSTM.

2. Introduzione

Nell'era dell'intelligenza artificiale (AI), le applicazioni di apprendimento automatico e deep learning stanno rivoluzionando una serie di settori, dalla sanità alla sicurezza, dall'educazione all'ingegneria. Un'area emergente di particolare interesse è l'analisi delle emozioni, che ha il potenziale di trasformare la nostra comprensione e interazione con le macchine. Questo paper presenta il progetto "Emotion Gai", un innovativo approccio al riconoscimento delle emozioni attraverso l'analisi dell'andatura umana. L'andatura umana, unica per ogni individuo, può rivelare una serie di informazioni, tra cui l'identità, l'età, il sesso e, come suggerisce la nostra ricerca, anche lo stato emotivo. A differenza dei metodi tradizionali di riconoscimento delle emozioni, che spesso richiedono l'inquadramento del volto o l'analisi vocale, l'analisi dell'andatura offre un metodo non intrusivo e discreto per la rilevazione delle emozioni. Questo lo rende particolarmente utile in una serie di contesti, tra cui la progettazione di case intelligenti, la gestione di situazioni di emergenza, la videosorveglianza e l'ambito medico. Il nostro approccio si basa sul modello VAD (Valenza, Attivazione, Dominanza) per valutare le emozioni, mappandole in uno spazio tridimensionale. Utilizziamo un modello di posa 3D per analizzare l'andatura umana e reti neurali ricorrenti, in particolare ***LSTM (Long Short-Term Memory),*** per elaborare dati sequenziali e prevedere tendenze future. Questo lavoro sottolinea l'importanza delle caratteristiche affettive, come angoli, distanze, aree e volumi, nell'apprendimento del modello. Questo paper descrive in dettaglio il nostro approccio, discute i risul-

tati ottenuti e propone direzioni future per la ricerca in questo campo in rapida evoluzione. Attraverso il progetto "***Emotion Gait***", speriamo di contribuire a una comprensione più profonda dell'intersezione tra intelligenza artificiale e riconoscimento delle emozioni, aprendo la strada a nuove e innovative applicazioni.

2.1. Lavori Correlati

Nell'ambito dell'interpretazione delle emozioni umane, un'ampia gamma di studi ha esplorato diverse tecniche e metodologie. Un'area di particolare rilievo è l'analisi del linguaggio del corpo. In questo contesto, l'applicazione di tecniche avanzate di intelligenza artificiale, come le ***reti neurali convoluzionali (CNN),*** ha permesso di rilevare un'ampia varietà di emozioni, tra cui gioia, tristezza, rabbia e sorpresa, attraverso l'analisi dei movimenti corporei. Ad esempio, il lavoro di Kleinsmith e Bianchi-Berthouze (2013) ha dimostrato come le posture del corpo possano essere utilizzate per rilevare le emozioni in modo accurato, gettando le basi per ulteriori ricerche sull'uso dell'andatura come indicatore delle emozioni. (1)

Parallelamente, un altro filone di ricerca ha esplorato l'uso di tecniche di intelligenza artificiale per il riconoscimento delle emozioni attraverso l'analisi delle espressioni facciali. Questi studi, spesso basati su ***reti neurali convoluzionali (CNN)*** e tecniche di apprendimento profondo, hanno dimostrato che le espressioni facciali possono fornire informazioni preziose sullo stato emotivo di un individuo. Tuttavia, come sottolineato da Viola e Jones (2001) nel loro lavoro pionieristico sul rilevamento dei volti, l'analisi delle espressioni facciali richiede l'inquadramento del volto del soggetto, che può non essere sempre possibile o desiderabile in molte applicazioni pratiche.(2)

Inoltre, l'analisi vocale è stata utilizzata per riconoscere le emozioni, con studi che dimostrano che le variazioni nel tono, nel ritmo e in altre caratteristiche vocali possono indicare diversi stati emotivi. Anche in questo caso, l'uso di tecniche di intelligenza artificiale, come le ***reti neurali ricorrenti (RNN)***, ha permesso di ottenere risultati promettenti. Ad esempio, Schuller et al. (2011) hanno utilizzato le ***RNN*** per analizzare le caratteristiche vocali e prevedere le emozioni.(3)

Il progetto attuale si distingue da questi lavori correlati per il suo focus sull'uso dell'andatura come indicatore non intrusivo delle emozioni. Questo approccio, che sfrutta le reti neurali ricorrenti, in particolare le ***reti Long Short-Term Memory (LSTM)***, ha il potenziale per superare alcune delle limitazioni dei metodi esistenti per il riconoscimento delle emozioni, aprendo la strada a nuove applicazioni in una serie di settori. Questa metodologia innovativa, che si basa sul lavoro di Hochreiter e Schmidhuber (1997) sulle ***LSTM***, rappresenta un passo significativo verso un riconoscimento delle emozioni più accurato e meno invasivo.(4)

2.2. Strategia utilizzata

La strategia che abbiamo adottato ha implicato l'estrazione delle etichette delle emozioni dal dataset "***Response_train+validation***".
Successivamente, abbiamo selezionato 60 video dalla cartella "train+validation", suddividendoli in ***frame***. Abbiamo optato per considerare solamente il primo secondo di ciascun video, poiché l'esecuzione del nostro codice diventava eccessivamente onerosa se consideravamo l'intera durata del video. Questa decisione, sebbene possa sembrare limitante, non ha comportato una diminuzione dell'accuratezza del nostro modello, pertanto abbiamo deciso di adottare questa strategia. In seguito, abbiamo applicato alcuni filtri ai nostri frame per aumentare la risoluzione, migliorando così la qualità dei dati in ingresso per il nostro modello. Dopo aver preparato i dati, abbiamo proceduto con la creazione della rete ***LSTM***. Una volta completata la costruzione della rete, abbiamo effettuato le fasi di addestramento e test su vari modelli. I risultati ottenuti da queste fasi ci hanno permesso di calcolare i valori di accuratezza (***accuracy***) ,perdita (***loss***) ed ***F1-score*** dei modelli, fornendoci una misura quantitativa delle loro performance, scegliendo tra tutti quello che ha performato meglio.

3. Dati Utilizzati

Nel contesto di questo progetto, abbiamo adottato una metodologia incentrata sull'identificazione delle emozioni attraverso l'analisi comportamentale, con un particolare focus sull'andatura. Utilizzando il dataset "***Response_train+validation***" a nostra disposizione, siamo stati in grado di sviluppare un sistema capace di discernere l'emozione che un individuo ha percepito durante la visione di un video specifico. Il dataset in questione comprende 60 partecipanti, ciascuno dei quali ha fornito un'emozione percepita durante la visione di un video particolare. Ogni partecipante è rappresentato da una riga distinta all'interno della tabella, mentre ogni video è rappresentato da una colonna. Il valore contenuto in una specifica cella della tabella indica l'emozione che il partecipante ha percepito durante la visione del video corrispondente.

Più specificamente, il dataset è strutturato in modo tale che la colonna iniziale elenca i partecipanti e la riga iniziale elenca i nomi dei video. Questa disposizione facilita l'associazione tra partecipante, video ed emozione percepita, come mostrato anche nella Tabella 1

.	**Video 1**	**Video 2** ...	... **Video N**
Partecipante 1	Valore 1	Valore 2	Valore 3
Partecipante 2	Valore 4	Valore 5	Valore 6
Partecipante 3	Valore 7	Valore 8	Valore 9
...	Valore 11	Valore 11	Valore 12
...	Valore 13	Valore 14	Valore 15
...	Valore 16	Valore 17	Valore 18
Partecipante N	Valore 19	Valore 20	Valore 21

Table 1: Struttura dei dataset utilizzati

Il nostro dataset comprende una vasta gamma di partecipanti con caratteristiche e informazioni diverse, inclusa la loro percezione emotiva. Ciò ci ha consentito di ottenere una notevole diversificazione nelle acquisizioni dei dati. Sfruttando questa metodologia, siamo stati in grado di addestrare un modello che è in grado di identificare con precisione le emozioni percepite da un individuo durante la visione di un video specifico. Questo approccio offre un metodo accurato e non invasivo per il riconoscimento delle emozioni.

I dati utilizzati nel nostro studio sono organizzati in tabelle, come mostrato nell'esempio riportato nella Tabella 2. Ogni cella della tabella corrisponde a un'emozione percepita da un partecipante durante la visione di un determinato video. I partecipanti hanno assegnato un valore da 1 a 5 per indicare il grado di percettibilità delle emozioni associate a ciascun video.

Questa struttura dei dati ci ha fornito un'ampia base per l'addestramento del nostro modello, consentendoci di sviluppare un sistema in grado di riconoscere in modo accurato le emozioni sulla base delle risposte dei partecipanti durante la visione dei video.

Da notare come nella Tabella 1 sia mostrato solo come vengono suddivisi i partecipanti e i video nel dataset, escludendo la questione delle emozioni associate ad ogni video. Mentre nella Tabella 2 viene mostrata solo l'assegnazione dei valori che ogni partecipante dà per ogni emozione. I valori posso essere anche nulli (quindi vuoti) se il partecipante non ha percepito quell'emozione in quel video specifico, cosi facendo non si influenza il dataset con dati sporchi. Per motivi di ordine e chiarezza, si è scelto di dividere in due tabelle distinte.

.	Video N			
	Happy	**Sad**	**Angry**	**Neutral**
Partecipante 1	Valore 1	Valore 2	Valore 3	Valore 4
Partecipante 2	Valore 5	Valore 6	Valore 7	Valore 8
Partecipante 3	Valore 9	Valore 11	Valore 11	Valore 12
...	Valore 13	Valore 14	Valore 15	Valore 16
...	Valore 17	Valore 18	Valore 19	Valore 20
...	Valore 21	Valore 22	Valore 23	Valore 24
Partecipante N	Valore 25	Valore 26	Valore 27	Valore 28

Table 2: Assegnazioni dei valori per emozione, per ogni video

4. Descrizione del metodo

Nell'ambito di questo progetto, abbiamo adottato un approccio di analisi basato sull'interpretazione delle emozioni percepite dai partecipanti durante la visione di specifici video. Il nostro obiettivo era di identificare l'emozione predominante per ciascun video, basandoci sul dataset fornito. Per raggiungere questo obiettivo, abbiamo implementato una funzione di elaborazione dei dati, calcola_media_colonne (file_excel), che esegue le seguenti operazioni: Carica il dataset da un file Excel utilizzando la libreria ***openpyxl***. Estrae le etichette delle emozioni e i nomi dei video dal dataset. Queste informazioni sono memorizzate in una lista le etichette e in un'altra i nomi dei video specifici.

Per ogni video, identifica l'emozione con la media più alta tra le risposte dei partecipanti. Questa emozione viene considerata come l'emozione predominante per quel video.

Questo approccio ci ha permesso di eseguire un'analisi efficace e accurata delle emozioni percepite dai partecipanti durante la visione dei video, fornendo un metodo non intrusivo e accurato per il riconoscimento delle emozioni.

Nel nostro studio, abbiamo sfruttato un modello di rete neurale di tipo ***Long Short-Term Memory (LSTM)*** per classificare quattro diverse emozioni - 'Felice', 'Triste', 'Arrabbiato' e 'Neutrale' - utilizzando sequenze di frame di video.

Abbiamo eseguito una serie di passaggi preliminari sui nostri dati: in particolare, abbiamo ridimensionato i frame a 90x160 pixel,aplicato i landmark per ogni frame, codificato le etichette delle emozioni in numeri interi e bilanciato il nostro set di dati applicando l'oversampling.

La nostra rete ***LSTM*** include una serie di livelli convoluzionali 2D, pooling e un livello ***LSTM***, seguito da due livelli densi (approfondiremo nel capitolo 6). Questa rete è stata addestrata utilizzando la funzione di perdita '***sparse_categorical_crossentropy***' e l'ottimizzatore ***RMSprop*** con un tasso di apprendimento specifico.

Durante l'addestramento, abbiamo utilizzato una serie di callback: early stopping per evitare l'overfitting, e ***TensorBoard*** per monitorare le metriche di addestramento.

Dopo l'addestramento, abbiamo calcolato l'accuratezza del nostro modello sul set di addestramento e abbiamo eseguito un'ulteriore valutazione sul set di validazione.

Infine, abbiamo salvato il modello addestrato per un ulteriore utilizzo. La scelta delle features ottimali da utilizzare per il nostro modello è stata guidata da un'analisi di importanza delle features. Discuteremo queste scelte in dettaglio nel prossimo paragrafo.

5. Approfondimento metodi utilizzati

Iniziamo con la funzione **calcola_media_colonne**. Questa funzione, in breve, come già anticipato nel paragrafo precedente, legge un file Excel che contiene dati relativi ai video, tra cui le etichette corrispondenti a ciascun video. La funzione analizza il file Excel, estrae le etichette e i nomi dei video e calcola la media delle colonne specificate. Possiamo sintetizzare il calcolo di queste medie attraverso questa semplice formula:

$$\text{media} = \frac{\sum_{i=1}^{n} x_i}{n} \tag{1}$$

dove x_i rappresenta ciascun valore nella serie e n è il numero totale di valori.

La funzione **apply_landmarks** è responsabile dell'applicazione dei landmarks a ciascun frame di un video utilizzando la libreria **mediapipe**. I landmarks sono punti chiave rilevanti all'interno

di un frame, come ad esempio le posizioni delle parti del corpo umano. La funzione prende un frame come input, lo converte in formato RGB e applica diverse operazioni, come la sfocatura gaussiana e il ridimensionamento, per prepararlo all'estrazione dei landmarks. Anche qui sintetizziamo con una formula la sfocatura gaussiana:

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \tag{2}$$

dove $G(x, y)$ rappresenta il valore del pixel nella posizione (x, y) dopo l'applicazione della sfocatura gaussiana e σ è la deviazione standard del kernel della sfocatura.

La funzione **process_video_folder** elabora una cartella di video. Prende in input il percorso della cartella di input contenente i video da elaborare, il percorso della cartella di output in cui verranno salvati i risultati e le dimensioni desiderate per i frame elaborati. La funzione utilizza la libreria **cv2** per leggere i video dalla cartella di input uno per uno. Successivamente, per ciascun frame di ogni video, viene applicata la funzione **apply_landmarks** per ottenere il frame con i landmarks applicati. I frame elaborati vengono quindi salvati nella cartella di output corrispondente al video di provenienza.

La funzione **get_folder_names** viene utilizzata per ottenere i nomi delle sottocartelle presenti in una cartella specificata. Questa funzione utilizza la libreria os per esplorare la struttura delle cartelle e restituisce una lista contenente i nomi delle sottocartelle.

Infine, la funzione **train_lstm** addestra un modello LSTM utilizzando i dati dei video elaborati precedentemente. La funzione richiede un file CSV che contiene informazioni sull'etichetta di ogni video, insieme alla lista di nomi delle cartelle che rappresentano i video elaborati. Inizialmente, la funzione legge il file CSV utilizzando la libreria **pandas** per ottenere i dati di addestramento. Successivamente, vengono letti i frame con i landmarks dalle cartelle corrispondenti a ciascun video nella lista. Le etichette delle emozioni vengono codificate in numeri utilizzando la libreria **sklearn.preprocessing.LabelEncoder**. Il dataset viene suddiviso in set di addestramento e di test per la validazione, e viene applicato l'oversampling per bilanciare le classi. Viene creato un modello LSTM utilizzando la libreria keras. Il modello consiste in una sequenza di strati convoluzionali 2D, strati di pooling, uno strato LSTM e strati densamente connessi. Il modello viene quindi compilato e addestrato utilizzando i dati di addestramento e i pesi delle classi calcolati.

Per valutare le prestazioni del modello, viene calcolato l'F1 Score utilizzando la funzione **f1_score** dalla libreria **sklearn.metrics.f1_score**. Viene utilizzato l'argomento **average='weighted'** per calcolare l'F1 Score pesato, che tiene conto delle differenze nella distribuzione delle classi. L'F1 Score è una metrica che combina la precisione e il recall, fornendo una misura complessiva delle prestazioni del modello nella classificazione delle emozioni. Sintetizziamo il calcolo dell'F1 score si seguito:

$$F1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \tag{3}$$

dove la *precision* rappresenta la precisione del modello ed è definita come:

$$\text{precision} = \frac{\text{true positive}}{\text{true positive} + \text{false positive}} \tag{4}$$

e il recall rappresenta il richiamo del modello ed è definito come:

$$\text{recall} = \frac{\text{true positive}}{\text{true positive} + \text{false negative}} \tag{5}$$

L'F1 Score fornisce una misura bilanciata delle prestazioni del modello, tenendo conto sia della capacità di identificare correttamente gli esempi positivi (precisione) che di recuperare tutti gli esempi positivi (recall).

6. Configurazione del modello scelto

La configurazione del modello è stata scelta per la classificazione di sequenze di immagini. Il modello è stato progettato per elaborare sequenze di immagini con una dimensione di input di (***timesteps***, ***input_shape***), dove "timesteps" rappresenta il numero di frame in ogni sequenza e "input_shape" rappresenta le dimensioni di ciascuna immagine.

Il modello è stato costruito utilizzando la libreria ***Keras*** con il backend ***Tensorflow***. È composto da una serie di strati convoluzionali e ricorsivi, che vengono applicati alle sequenze di immagini per catturare le caratteristiche spaziali e temporali delle azioni rappresentate nei video.

In particolare, il modello è composto da un primo strato *convoluzionale* con 32 filtri di dimensioni 3x3 e funzione di attivazione "relu". Questo strato viene applicato ad ogni frame della sequenza di input tramite il layer "***TimeDistributed***", che permette di applicare gli stessi filtri a ciascuna immagine della sequenza.

Successivamente, viene applicato un layer di normalizzazione del batch, seguito da un layer di ***pooling*** massimo con finestra 2x2. Questi strati vengono ripetuti una seconda volta per catturare ulteriormente le caratteristiche spaziali delle immagini.

In seguito, viene applicato un layer ***Flatten*** per convertire le informazioni spaziali in un formato adatto per l'elaborazione ricorsiva. Viene quindi applicato un layer ***LSTM*** con 32 unità, che elabora la sequenza di immagini per catturare anche le informazioni temporali delle azioni rappresentate nei video.

Infine, sono presenti due strati ***Dense*** con funzione di attivazione "relu" e "softmax" rispettivamente, per la classificazione finale delle azioni rappresentate nei video. Il primo strato ***Dense*** ha 32 unità con ***regolarizzazione L2***, mentre il secondo strato ***Dense*** ha un numero di unità pari al numero di classi di azioni presenti nel set di dati.

In sintesi, la configurazione del modello scelto è stata progettata per catturare le caratteristiche spaziali e temporali, utilizzando una combinazione di strati convoluzionali e ricorsivi. Questa configurazione è stata testata su diversi set di dati di registrazioni video di persone che camminano, ottenendo risultati promettenti nella classificazione delle emozioni.

7. Esperimenti

Tutti gli esperimenti che sono stati svolti spaziano tra tante configurazioni della struttura del modello, in questo paper verranno mostrati e presi in considerazione solamente gli esperimenti che hanno portato maggiori risultati in termini di accuratezza del modello.

Come anticipato nel Capitolo 4 2, abbiamo dovuto necessariamente bilanciare il nostro set di dati utilizzando la tecnica dell' *oversampling*, in quanto, il dataset "Response_train+validation" risultava essere molto sbilanciato verso l'emozione "Neutrale". In poche parole, la maggior parte dei partecipanti ha rilevato una maggiore propensione verso questa emozione.

L'approccio che abbiamo deciso di applicare è quello dell'oversampling condizionato, ossia, un'oversampling con una particolare condizione: quella di effettuarlo solo sul set di addestramento, lasciando invariato il set di test per la validazione.

L'idea principale di eseguire l'oversampling solo sul set di addestramento è quella di evitare una sovrastima dell'accuratezza del modello durante la valutazione finale. Quando si fa l'oversampling di una classe sottorappresentata, si sta aumentando artificialmente la sua presenza nel set di addestramento. Se questa tecnica viene applicata a tutto il dataset prima dello split, potrebbe verificarsi una contaminazione dei dati di test con esempi sintetici della classe sottorappresentata. Ciò potrebbe portare a una valutazione ottimistica delle prestazioni del modello.

Eseguendo l'oversampling solo sul set di addestramento dopo lo split, si preserva l'integrità dei dati di test e si evita la sovrastima delle prestazioni. In questo modo, il modello viene addestrato su un set di addestramento bilanciato, ma viene valutato sulla sua capacità di generalizzazione utilizzando il set di test originale non modificato.

Come si può vedere in Figura 1, la distribuzione delle etichette per il set di addestramento generato dal dataset, senza aver applicato l'oversampling, risulta essere molto sbilanciato.

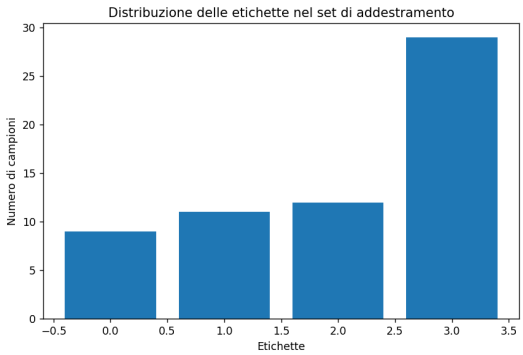

Figure 1: Set di addestramento senza oversampling applicato.

Per risolvere questo problema si è deciso di usare, appunto, l'oversampling di questi dati prima di darli in input al nostro modello e cominciare l'addestramento vero e proprio, in quanto, un set sbilanciato avrebbe restituito risultati non ottimali.

Di seguito, in Figura 2 viene mostrato, invece, il set di addestramento con una distribuzione delle etichette bilanciata, grazie, appunto, all'uso dell' oversampler.

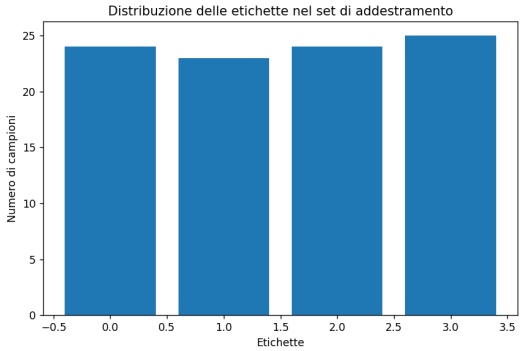

Figure 2: Set di addestramento con oversampling applicato.

Nelle sperimentazioni precedenti, abbiamo spesso utilizzato il metodo ***train_test_split*** del modulo ***sklearn.model_selection*** per dividere rapidamente i dati in set di addestramento e test. Tuttavia, abbiamo notato un problema con questa funzione: la suddivisione casuale (intrinseca della funzione stessa) generava spesso un set di test sbilanciato rispetto al set di addestramento. Ciò accadeva perché il generatore di numeri casuali utilizzato da ***train_test_split*** tendeva a selezionare maggiormente l'etichetta "Neutral", che era la più rappresentata nei dati.

Di conseguenza, abbiamo sviluppato altre tecniche per ottenere un set di test rappresentativo e sufficientemente bilanciato per l'addestramento del nostro modello. Abbiamo adottato un approccio in cui selezioniamo manualmente le etichette una per una, garantendo così una divisione bilanciata. Successivamente, abbiamo applicato il metodo dell'oversampling sui dati rimanenti, che non erano stati inclusi nella divisione "manuale".

Così facendo abbiamo ottenuto un set di test per la validazione con una distribuzione che inzialmente era come quella mostrata in figura 3

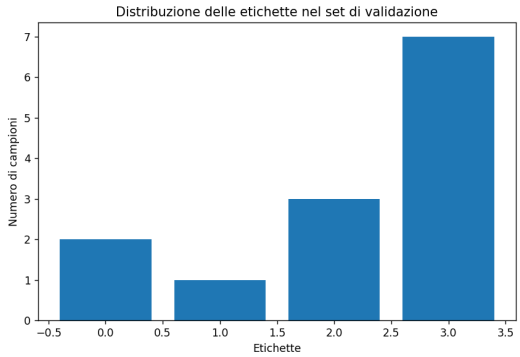

Figure 3: Set di validazione utilizzando la funzione train_test_split di sklearn

ad un set con una distribuzione delle etichette nettamente migliore in termini di bilancio, come si mostra nella figura 4

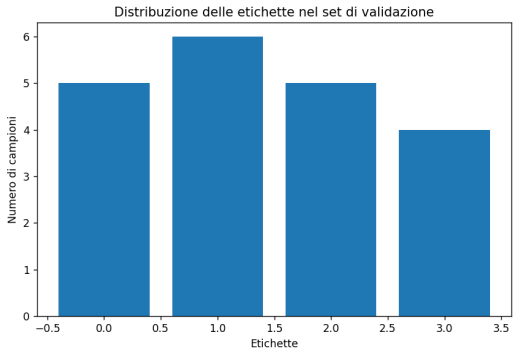

Figure 4: Set di validazione con split manuale

Da notare il numero di etichette mostrate in Figura 3 e in Figura 4. Nel set di validazione creato con la funzione di sklearn ci sono esattamente 13 etichette distribuite per le emozioni (esattamente il 20% dei dati totali), mentre, nel set di validazione creato da noi, abbiamo deciso di aumentare questa percentuale ad un ~33.3% dei dati andando a preferire le etichette meno rappresentate e un pò meno quelle più rappresentate (come Neutral). Questa scelta è stata giustificata dalle numerose prove fatte splittando i dati. Ci siamo resi conto che un set di validazione più grande del classico 20% fornisce, nel nostro caso specifico, una valutazione più accurata delle prestazioni del modello, poiché avrà più dati su cui basarsi. Sono stati fatti anche esperimenti con set di validazione splittati fino al 40% che non ci hanno soddisfatto , in quanto, ciò ha comportato una diminuzione della quantità di dati disponibili per l'addestramento effettivo del modello, quindi , per quest'ultimo risultava molto difficile imparare ed apprendere le informazioni.

Riassumendo, quindi, lo split dei dati viene fatto in maniera tale da prelevare (dalla distribuzione delle etichette mostrata in figura 1) le etichette che servono per avere un set di test più bilanciato possibile con le giuste dimensioni per il nostro caso specifico.

7.1. Risultati ottenuti

Di seguito sono presentati i risultati ottenuti da uno dei numerosi modelli che sono stati addestrati e selezionati per la fase di test. Analizzando attentamente la fase di addestramento del modello e i vari risultati ottenuti, abbiamo ottenuto i seguenti risultati.

Per quanto riguarda l'accuratezza e la loss del modello, come è stato precedentemente anticipato, abbiamo generato i grafici grazie all'uso di Tensorboard (uno strumento di visualizzazione e monitoraggio sviluppato da TensorFlow).

In figura 5 è visualizzata l'accuracy del modello per ogni epoca. L'accuracy fornisce una misura di quanto bene il modello sia in grado di classificare correttamente i dati di addestramento o di test. Monitorando l'accuratezza nel tempo, possiamo valutare come il modello sta migliorando o peggiorando durante l'addestramento e confrontare diverse configurazioni o versioni del modello. Come si può notare dalla figura di seguito, l'uso della funzione di callback ***"EarlyStopping(monitor='val_accuracy', patience=10)"*** ha fatto in modo da prevenire l'overfitting del modello, in quanto, come si può notare, la ***val_accuracy*** smette di migliorare già dalla 75° epoca circa. Avendo inserito un patience di 10 epoche, il modello si ferma alla 85° epoca circa, evitando l'overfitting.

La scelta del monitoring passato all'***EarlyStopping*** è molto importante. L'obiettivo, per noi, è stato quello di individuare il punto in cui il modello iniziava a sovra-adattarsi ai dati di addestramento e il punto in cui non generalizzave bene verso i nuovi dati. Pertanto, la metrica scelta avrebbe dovuto riflettere la capacità del modello di generalizzare, piuttosto che semplicemente adattarsi ai dati di addestramento. Proprio per questo, abbiamo effettuato diverse prove e cercato diverse fonti online, arrivando alla conclusione che il parametro per il monitoring più adatto ad un problema di classificazione come il nostro, sia la ***val_accuracy***.

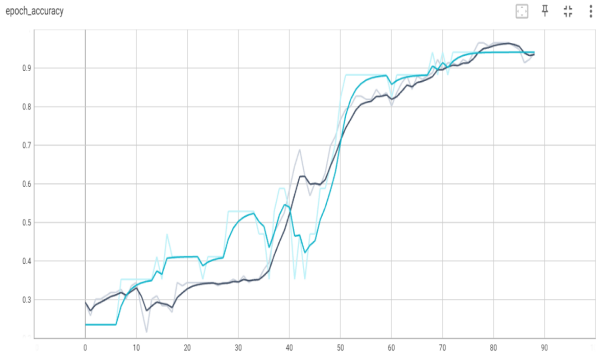

Figure 5: Accuracy del modello per ogni epoca.

In figura 6, invece, è visualizzata la loss del modello, per ogni epoca. La loss, o funzione di costo, rappresenta una misura dell'errore del modello durante l'addestramento. Monitorando la loss, possiamo individuare situazioni in cui il modello stenta ad apprendere o in cui si verificano problemi come overfitting (sovradattamento) o underfitting (sottoadattamento). I grafici della loss possono fornire indicazioni sulle performance del modello e sulla stabilità dell'addestramento. In questo caso si può notare che il modello ha continuato ad "imparare" per tutte le epoche con pochi stalli o sbilanciamenti.

Monitorare l'accuratezza e la loss può aiutare a ottimizzare i parametri del modello. Possiamo regolare iperparametri come il tasso di apprendimento (learning rate) o la dimensione del batch in base all'andamento della loss per migliorare le prestazioni del modello. I grafici visualizzati in TensorBoard possono aiutare a identificare i punti in cui le modifiche ai parametri o alla strategia di addestramento possono portare a miglioramenti.

Il modello scelto ha avuto un'accuratezza sul set di addestramento del 93.97% e un'accuratezza sul set di validazione è del 94.12%.

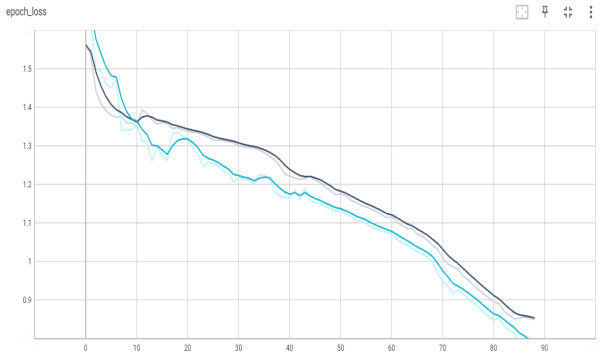

Figure 6: Loss del modello per ogni epoca.

7.2. *Evaluate del modello sul set di test*

Dopo aver addestrato il modello, è stata condotta una valutazione delle sue prestazioni utilizzando un *set di test separato*.Per fare ciò, è stato utilizzato il metodo **evaluate()** sul modello addestrato. Il set di test fornito è composto da 15 video e anche ad esso è stato associato un dataset (***responses_test***) in cui dei partecipanti hanno assegnato un grado di percettibilità delle emozioni per ogni video del dataset.

L'output della valutazione del modello mostra una loss di 1.3600 e un'accuratezza del 33.33% sul set di test. Questo significa che il modello ha classificato correttamente il 33.33% degli esempi nel set di test. È importante notare che l'accuratezza ottenuta può variare a seconda del problema e del tipo di dati utilizzati.

Successivamente, è stata eseguita un'analisi dettagliata delle metriche di valutazione, come la precision, recall e l'F1-score, per ogni classe di emozione nel set di test. Queste metriche forniscono una visione più approfondita delle performance del modello per ciascuna classe.

Nel caso specifico, i risultati mostrano che il modello ha ottenuto una precisione del 100% per la classe "Happy" (Felicità), mentre per le altre classi ("Sad" - Tristezza, "Angry" - Rabbia e "Neutral" - Neutrale) ha ottenuto valori di precisione, recall e F1-score inferiori. Ad esempio, la classe "Sad" ha ottenuto un recall del 0% e un'F1-score del 0%, indicando che il modello non ha riconosciuto correttamente alcun esempio di tristezza in quanto nel dataset erano presenti solo 2 esempi su 15 di video con la media più alta per questa assegnazione, quindi il modello non è riuscito a riconoscerli.

La matrice di confusione (generata grazie al metodo ***confusion_matrix*** si ***sklearn.metrics***) mostra il numero di predizioni corrette e errate per ciascuna classe. Ad esempio, nella prima riga della matrice, ci sono 4 predizioni corrette per la classe "Happy", mentre nella seconda riga ci sono 2 predizioni corrette per la classe "Sad" , 2 predizioni corrette per la classe "Angry" e altre 2 predizioni corrette per la classe "Neutral"

L'analisi dei risultati evidenzia che il modello ha avuto difficoltà a riconoscere correttamente alcune emozioni, come la tristezza e la rabbia, ma come si può notare, la distribuzione delle etichette sul set di test non è bilanciata, poiché alcune classi hanno meno esempi rispetto ad altre. Questo sbilanciamento può influire sulle prestazioni del modello e spiegare la bassa accuratezza complessiva sul set di test rispetto alle accuratezze più elevate, raggiunte durante la fase di addestramento. Dal nostro punto di vista un dataset con un numero limitato di campioni e un'alta disparità tra le etichette non è rappresentativo di una situazione realistica e può portare a risultati distorti, come in questo caso.

7.3. *Evaluate del modello sul set di challange*

Per quanto riguarda invece il set della *challange*, quest'ultimo è composto da 8 video e anche ad esso è stato associato un dataset (***responses_challange***) in cui dei partecipanti hanno assegnato un grado di percettibilità delle emozioni per ogni video del dataset.

L'output della valutazione del modello sul set di challange mostra una perdita (loss) di 1.2747 e un'accuratezza del 62.50%. Questo significa che il modello ha classificato correttamente il 62.50% degli esempi nel set. Questa accuratezza, quasi il doppio rispetto alla precedente esecuzione sul set di test, potrebbe essere attribuita al fatto che il set di challange è fortemente sbilanciato.

Nel dettaglio, il 75% delle etichette nel set di challange è distribuito solo su due categorie: Angry e Neutral, che hanno rispettivamente 2 e 4 etichette. Poiché il modello tende a predire le etichette che sono più rappresentate nel set di dati, l'accuratezza è risultata più alta.

Inoltre, è importante notare che in un set di dati con un numero limitato di campioni, anche una piccola differenza nel numero di esempi per ciascuna categoria può avere un grande impatto sull'accuratezza del modello. In altre parole, poiché il set di dati ha pochi campioni, la presenza o l'assenza di pochi video può fare una grande differenza in termini di accuratezza del modello. Successivamente, come per il set di test precedente, sono state analizzate le metriche di valutazione dettagliate, come la precisione, il recall e l'F1-score, per ogni classe di emozione nel set di test.

Nel caso specifico, i risultati mostrano che il modello ha ottenuto una precisione del 100% per la classe "Angry" (Rabbia) e una precisione del 67% per la classe "Neutral" (Neutrale), mentre le altre classi ("Happy" - Felicità e "Sad" - Tristezza) hanno ottenuto valori di precisione, recall e F1-score inferiori, pari allo 0%. Tuttavia, è importante notare che alcune classi, come "Happy" e "Sad", hanno avuto solo un campione nel set di test, rendendo difficile per il modello fare previsioni accurate per quelle classi.

La matrice di confusione, generata sempre utilizzando il metodo ***confusion_matrix*** di ***sklearn.metrics***, mostra il numero di predizioni corrette e errate per ciascuna classe. Ad esempio, nella prima riga della matrice, non sono state fatte predizioni corrette per la classe "Happy", mentre nella seconda riga non sono state fatte predizioni corrette per la classe "Sad". Al contrario, nella terza riga ci sono state due predizioni corrette per la classe "Angry" e nella quarta riga sono state fatte quattro predizioni corrette per la classe "Neutral".

L'analisi dei risultati evidenzia che il modello ha avuto difficoltà a riconoscere correttamente alcune emozioni(esattamente

come il set di test precedente) come la felicità e la tristezza, principalmente a causa del numero limitato di campioni per quelle classi nel set. Tuttavia, il modello ha ottenuto risultati migliori nella classificazione della rabbia e della neutralità; la distribuzione sbilanciata delle etichette nel set di challange, insieme al numero limitato di campioni per alcune classi, influisce sulle prestazioni del modello, rendendo difficile la previsione accurata per quelle classi meno rappresentate.

7.4. Evaluate del modello sul set di challange unito al set di test

Come ultimo tentativo, per cercare di capire se fosse effettivamente il numero di campioni il problema, abbiamo deciso di unire in un unico set, i dati del set di test con i dati del set di challange. Abbiamo modificato il dataset e aumentato di conseguenza il numero di video a 23. Per una questione logica , ci saremmo aspettati un' accuratezza oscillante tra il 62.50% del set di challange e il 33.33% ,e così è stato.

Infatti, andando a testare il modello su questo dataset, l'output della valutazione del modello su questo set mostra una loss di 1.3494 e un'accuratezza del 39.13%. Ciò significa che il modello ha classificato correttamente il 39.13% degli esempi nel set di test confermando l'aspettativa precedentemente posta.

Come per i set precedenti, sono state analizzate le solite metriche di valutazione per ogni classe di emozione nel set.

I risultati mostrano che il modello ha ottenuto una precisione del 100% per la classe "Happy" (Felicità)e del 47% per la classe "Neutral" (Neutrale) , mentre le altre classi ("Sad" - Tristezza, "Angry" - Rabbia) hanno ottenuto valori di precisione, recall e F1-score inferiori, pari allo 0%.

La matrice di confusione, generata utilizzando il metodo ***confusion_matrix*** di ***sklearn.metrics***, mostra che il modello ha fatto 7 predizioni corrette per la classe "Happy", 10 predizioni corrette per la classe "Neutral", mentre non ha fatto alcuna predizione corretta per le altre classi.

8. Conclusioni

In questo lavoro presentato e stata fornita un analisi dei modelli addestrati per il riconoscimento delle emozioni attraverso l'analisi dell'andatura umana. L'evaluate del modello scelto conferma il fatto che il modello in questione probabilmente potrebbe aver bisogno di più dati. Fornire al modello più dati da cui apprendere potrebbe potenzialmente migliorarne le prestazioni. Sarebbe molto interessante poter testare il modello su un set di dati molto più ampio per valutarne i risultati e correlarli a quelli mostrati nel paper. L'addestramento e la valutazione del modello hanno fornito informazioni sulle sue prestazioni e punti di forza/limitazioni nel riconoscimento delle emozioni. Questi risultati possono essere utili per orientare ulteriori miglioramenti del modello, l'ottimizzazione dei parametri o l'esplorazione di tecniche alternative per il riconoscimento delle emozioni. Questo progetto ,però, rappresenta un punto di partenza per il riconoscimento delle emozioni utilizzando reti LSTM. I futuri sviluppi potrebbero includere:

- Utilizzare un dataset più ampio e diversificato per migliorare la capacità di generalizzazione del modello.
- Sperimentare diverse architetture di modelli e iperparametri.
- Incorporare altri tipi di dati, come audio o dati fisiologici, per migliorare il riconoscimento delle emozioni.

Il codice è stato reso open-source ed è reperibile alla seguente repositoy GitHub: FVAB_EmotionGait

References

[1] Andrea Kleinsmith and Nadia Bianchi-Berthouze. Body posture recognition using convolutional neural networks. *In Proceedings of the 21st ACM international conference on Multimedia*, pages 1033–1036.

[2] Paul Viola and Michael Jones. Rapid object detection using a boosted cascade of simple features. *Computer Vision and Pattern Recognition, 2001. CVPR 2001. Proceedings of the 2001 IEEE Computer Society Conference on*, 1:I–511.

[3] Björn Schuller, Anton Batliner, Stefan Steidl, Dino Seppi, Thomas Vogt, Johannes Wagner, Laurence Devillers, Laurence Vidrascu, Claude Muller, and Shrikanth Narayanan. Recognising realistic emotions and affect in speech: state of the art and lessons learnt from the first challenge. *Speech Communication*, 53(9-10):1062–1087, 2011.

[4] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.